

# Grundlegende Begriffe

## Symbole und Begriffe

$\omega$  = Ergebnis:

Ergebnis eines Zufallsexperiment

$\Omega$  = Ergebnismenge:  
↳ auch Ergebnisraum

Menge aller möglichen Ergebnisse eines Zufallsexperiment

$|\Omega|$  = Mächtigkeit von  $\Omega$ :  
↳ auch Kardinalität

Anzahl aller möglichen Ergebnissen (Anz. Elemente in  $\Omega$ )

$E$  = Ereignis:

Teilmenge der Ergebnismenge ( $E \subseteq \Omega$ )

$\{\omega\}$  = Elementarereignis:

Ereignis mit nur einem Ergebnis ( $\{\omega\} \subseteq \Omega$ )

$\Sigma$  = Ereignisalgebra:

Menge aller in einem Zufallsexperiment zu betrachtenden Ereignisse

$P$  = Wahrscheinlichkeit:  
↳ kurz Wkeit

Wahrscheinlichkeit (maß) ist Funktion, welche jedem Ereignis seine Wahrscheinlichkeit zuordnet:  $P : \Sigma \rightarrow [0, 1]$

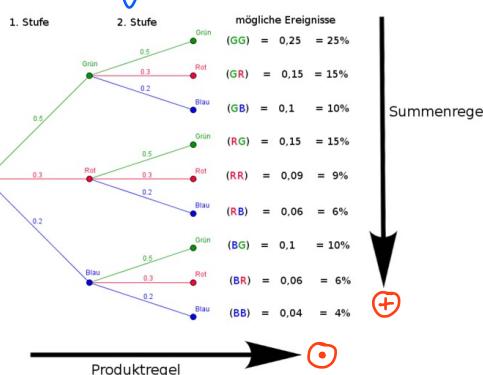
$$E \mapsto P(E)$$

Wahrscheinlichkeitsraum :=  $(\Omega, \Sigma, P)$

→ diskret, falls  $\Omega$  endlich oder abzählbar ist, z.B.  $\Omega = \mathbb{N}$

oft hilfreich:

Baumdiagramm



## Wahrscheinlichkeit und Mengenlehre

$\bar{A} (= A^c)$	Komplement von A / kein Elementarereignis aus A findet statt
$A \cap B$	Schnittmenge von A und B $\Rightarrow$ ein Elementarereignis aus A und B findet statt
$A \cup B$	Vereinigung von A und B $\Rightarrow$ ein Elementarereignis aus A oder B findet statt
$A \setminus B$	A ohne B $\Rightarrow$ ein Elementarereignis aus A tritt ein, aber nicht aus B.
$A \subset B$	A ist eine Teilmenge von B $\Rightarrow$ wenn ein Elementarereignis aus A stattfindet, dann immer auch ein Elementarereignis aus B

## Klassische Wahrscheinlichkeit

Die klassische Wahrscheinlichkeit tritt dann auf, wenn die Anzahl der Elementarereignisse endlich ist und alle Elementarereignisse gleich wahrscheinlich sind. (Auch Laplace Wahrscheinlichkeit genannt)

$$p = \frac{\text{Anzahl günstige Fälle}}{\text{Anzahl mögliche Fälle}} = \frac{|E|}{|\Omega|}$$

Vorgehen:

- Ereignisraum  $\Omega$  bestimmen für alle möglichen Fälle und Ereignis  $E$  bestimmen für alle günstigen Fälle.
- Die Kardinalität  $|\Omega|$  bzw.  $|E|$  bestimmen, um die Anzahl möglichen Fälle und die Anzahl günstigen Fälle zu erhalten. **oft mit Kombinatorik**
- Formel für klassische Wahrscheinlichkeit anwenden.

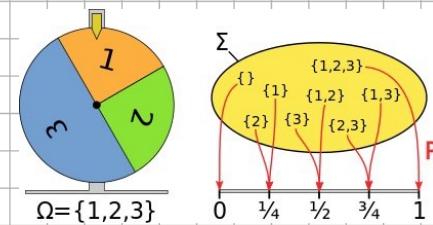
## Geometrische Wahrscheinlichkeit

Die Wahrscheinlichkeit ist proportional zur Masszahl eines Flächeninhalts oder ein anderes geometrisches Objekt.

$$p = \frac{\text{günstige Fläche}}{\text{mögliche Fläche}}$$

Vorgehen:

- Geometrisches Objekt zeichnen.
- Mögliche Fläche markieren und berechnen (Bruchteil, der die mögliche Fläche des Ganzen ausmacht).
- Günstige Fläche markieren und berechnen (Bruchteil, der die günstige Fläche des Ganzen ausmacht).
- Formel für geometrische Wahrscheinlichkeit anwenden.



# Redenregeln Wahrscheinlichkeit

$0 \leq P[E] \leq 1$  für alle E.

$P(\Omega) = 1$  sicheres Ereignis

$P(\emptyset) = 0$  unmögliches Ereignis

$P(\bar{E}) = 1 - P(E)$  Komplementäreignis (oft hilfreich)

$P(E \cup F) = P(E) + P(F) - P(E \cap F)$  Vereinigung

$P(E \cup F) = P(E) + P(F)$  falls  $E \cap F = \emptyset$  (unvereinbar = disjunkt)

für mehr als 2 Ereignisse: Siebformel

$$P(E_1 \cup \dots \cup E_n) = \sum_{1=j_1}^n P(E_{j_1}) - \sum_{1=j_1 < j_2}^n P(E_{j_1} \cap E_{j_2}) + \sum_{1=j_1 < j_2 < j_3}^n P(E_{j_1} \cap E_{j_2} \cap E_{j_3}) + \dots + (-1)^{n+1} P(E_1 \cap \dots \cap E_n)$$

$$= \sum_{k=1}^n (-1)^{k+1} \sum_{1=j_1 < j_2 < \dots < j_k}^n P(E_{j_1} \cap E_{j_2} \cap \dots \cap E_{j_k}) \rightarrow S3A8$$

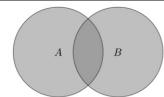
falls W'keiten der Schnittmengen mit gleicher Anzahl Teilmengen gleich sind "vereinfacht" sich die Formel zu:

$$nP(A_1) - \binom{n}{2} P(A_1 \cap A_2) + \binom{n}{3} P(A_1 \cap A_2 \cap A_3) - \binom{n}{4} P(A_1 \cap A_2 \cap A_3 \cap A_4)$$

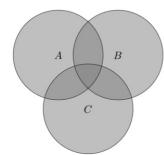
$$+ \binom{n}{5} P(A_1 \cap A_2 \cap A_3 \cap A_4 \cap A_5) - \dots + \dots + (-1)^{n+1} P(A_1 \cap \dots \cap A_n),$$

$\rightarrow S3A8$

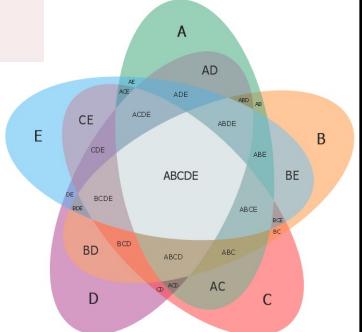
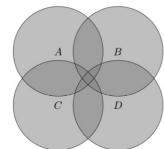
$$|A \cup B| = |A| + |B| - |A \cap B|$$



$$|A \cup B \cup C| = |A| + |B| + |C| - |A \cap B| - |A \cap C| - |B \cap C| + |A \cap B \cap C|$$



$$|A \cup B \cup C \cup D| = |A| + |B| + |C| + |D| - |A \cap B| - |A \cap C| - |A \cap D| - |B \cap C| - |B \cap D| - |C \cap D| + |A \cap B \cap C| + |A \cap B \cap D| + |A \cap C \cap D| + |B \cap C \cap D| - |A \cap B \cap C \cap D|$$



## Bonferroni - Ungleichungen

In der Siebformel werden die grösseren Durchschnitte immer kleiner

=> Wir erhalten eine obere Grenze für die Wahrscheinlichkeit der Vereinigung, wenn wir in der Formel nach einer positiven Summe abbrechen und eine untere Grenze wenn wir nach einer negativen Summe abbrechen:

$$P(E_1 \cup \dots \cup E_n) \leq \sum_{1=j_1}^n P(E_{j_1}) \rightarrow S4A1$$

$$P(E_1 \cup \dots \cup E_n) \geq \sum_{1=j_1}^n P(E_{j_1}) - \sum_{1=j_1 < j_2}^n P(E_{j_1} \cap E_{j_2})$$

$$P(E_1 \cup \dots \cup E_n) \leq \sum_{1=j_1}^n P(E_{j_1}) - \sum_{1=j_1 < j_2}^n P(E_{j_1} \cap E_{j_2}) + \sum_{1=j_1 < j_2 < j_3}^n P(E_{j_1} \cap E_{j_2} \cap E_{j_3})$$

:



## Unabhängigkeit von Ereignissen

A und B sind (paarweise) unabhängig voneinander und beeinflussen sich somit nicht, wenn gilt:

$$P(A \cap B) = P(A) \cdot P(B) \quad \text{Schnittmenge}$$

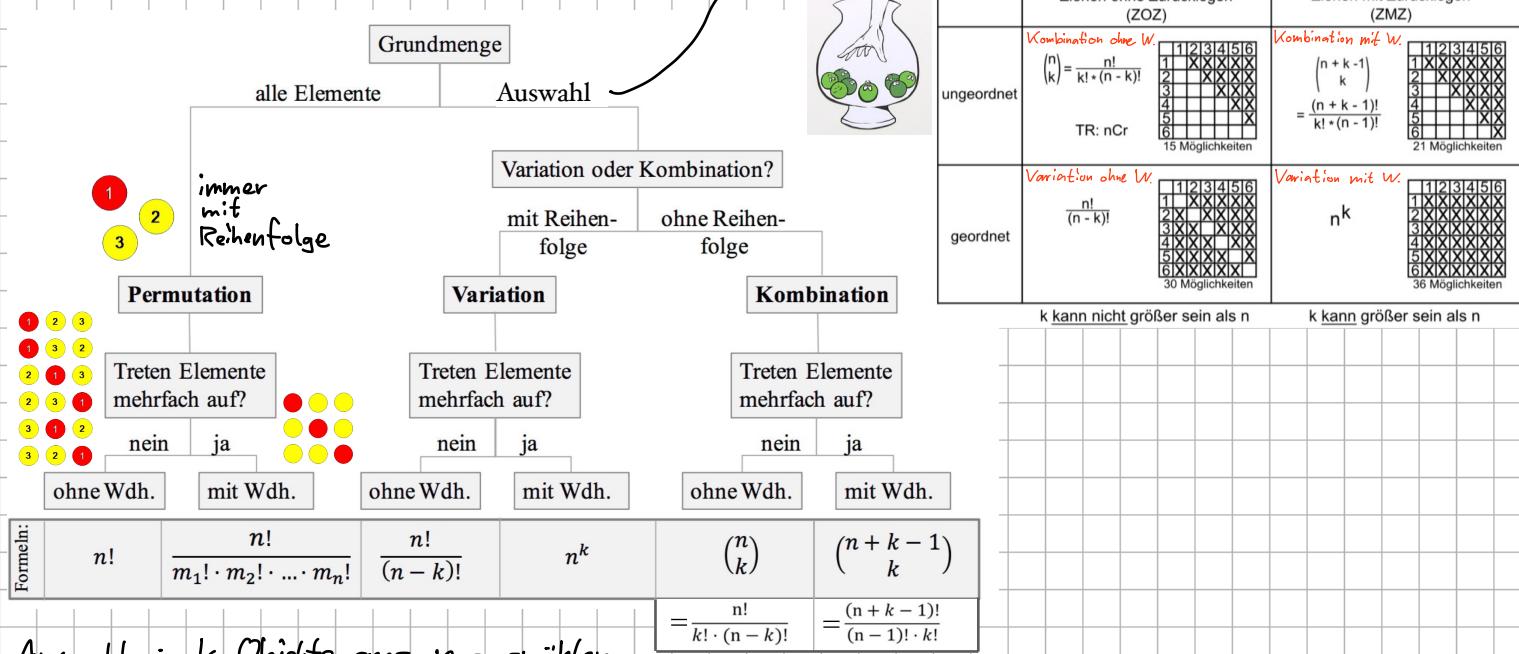
$$P(A|B) = P(A)$$

Dabei ist zu beachten, dass unabhängig nicht das Gleiche ist wie disjunkt!

$$P(A \cap B) = P(A) \cdot P(B) \neq P(A \cap B) = 0$$

unabhängig  $\neq$  disjunkt  
→ schließen sich gegenseitig aus

# Kombinatorik



Anzahl: k Objekte aus n auswählen

Reihenfolge: ABC ist nicht das gleiche wie CBA

Wiederholung: Objekte dürfen mehrmals benutzt / gezogen werden

Anzahl k-te partielle Ableitungen von  $f: \mathbb{R}^n \rightarrow \mathbb{R}$  (siehe Satz von Schwarz, AN3)

Anzahl Ableitungen ohne Satz von Schwarz:  $n^k$

Anzahl Möglichkeiten k Variablen aus n abzuleiten  
wobei es auf die Reihenfolge ankommt  
und die Variablen mehrmals gewählt werden dürfen

→ Variation mit Wdh.

Anzahl  
mit Reihenfolge  
mit Wdh.

1	2	3	4	5	6
X	X	X	X	X	X
X	X	X	X	X	X
X	X	X	X	X	X
X	X	X	X	X	X

36 Möglichkeiten

Anzahl zu berechnender Ableitungen für Hesse-Matrix (bei  $n=6$ )

1	2	3	4	5	6
X	X	X	X	X	X
X	X	X	X	X	X
X	X	X	X	X	X
X	X	X	X	X	X

21 Möglichkeiten

Anzahl zu berechnender Ableitungen für Hesse-Matrix (bei  $n=6$ )

Anzahl Ableitungen mit Satz von Schwarz:  $\binom{k+n-1}{k}$

Anzahl Möglichkeiten k Variablen aus n abzuleiten  
wobei es nicht auf die Reihenfolge ankommt  
und die Variablen mehrmals gewählt werden dürfen

→ Kombination mit Wdh.

Anzahl  
ohne Reihenfolge  
mit Wdh.

1	2	3	4	5	6
X	X	X	X	X	X
X	X	X	X	X	X
X	X	X	X	X	X
X	X	X	X	X	X

Anzahl zu berechnender Ableitungen für Hesse-Matrix (bei  $n=6$ )

## Binomialkoeffizienten

$$\binom{n}{k} = \frac{n!}{k! \cdot (n-k)!}$$

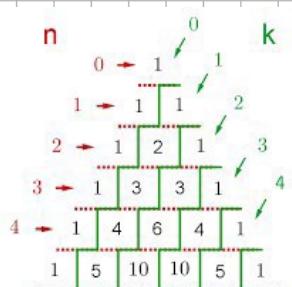
< n tief k >  
 < n choose k >  
 → TR:  $nCr(n, r)$

Anzahl Möglichkeiten k Objekte aus n auszuwählen (Komb. ohne Wdh.)

wichtige Spezialfälle:  
 $(\cong$  Rand d. pascalschen Dreiecks)

$$\binom{n}{0} = \binom{n}{n} = 1, \quad \binom{n}{1} = \binom{n}{n-1} = n$$

pascalsches Dreieck



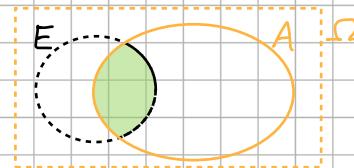
# Bedingte Wahrscheinlichkeit

$$P(E|A) = \frac{P(E \cap A)}{P(A)}$$

auch  $P_A(E)$

$\Leftrightarrow E$  gegeben  $A \gg$

Wahrscheinlichkeit, dass  $E$  eintritt gegeben dass  $A$  eingetreten ist



$$\begin{array}{ll} P(A) & A \\ P(E|A) & \bar{E} \\ P(E \cap A) & P(\bar{E}|A) \\ P(A) & E \\ P(E \cap \bar{A}) & P(\bar{E} \cap \bar{A}) \\ P(\bar{A}) & \bar{E} \\ P(E \cap \bar{A}) & P(\bar{E} \cap \bar{A}) \end{array}$$

Multiplikationsregel: Schnittmenge mithilfe bedingter Wklt

2 Ereignisse:

$$P(E \cap A) = P(E|A) \cdot P(A)$$

Multiplikation entlang Ast:

$$\begin{array}{c} P(A) \quad P(E|A) \\ \diagdown \quad \diagup \\ P(A) \quad P(E \cap A) \\ \diagup \quad \diagdown \\ P(\bar{A}) \quad P(E|\bar{A}) \\ \diagdown \quad \diagup \\ P(\bar{A}) \quad P(E \cap \bar{A}) \end{array}$$

mehr als 2 Ereignisse:

$$\begin{aligned} P(E_n \cap E_{n-1} \cap \dots \cap E_1) \\ = P(E_n | E_{n-1} \cap E_{n-2} \cap \dots \cap E_1) \cdot P(E_{n-1} | E_{n-2} \cap E_{n-3} \cap \dots \cap E_1) \cdot \\ \dots \cdot P(E_2 | E_1) \cdot P(E_1). \end{aligned}$$

$$\begin{aligned} \text{Herleitung: } \\ P(E_n \cap E_{n-1} \cap \dots \cap E_1) \\ = \frac{P(E_n \cap E_{n-1} \cap \dots \cap E_1)}{P(E_{n-1} \cap E_{n-2} \cap \dots \cap E_1)} \cdot \frac{P(E_{n-1} \cap E_{n-2} \cap \dots \cap E_1)}{P(E_{n-2} \cap E_{n-3} \cap \dots \cap E_1)} \cdot \\ \dots \cdot \frac{P(E_2 \cap E_1)}{P(E_1)} \cdot P(E_1) \end{aligned}$$

$$\begin{array}{ccccccc} P(E) & \diagdown & E_1 & \diagup & P(E_2 | E_1) & \dots & E_{n-1} & \diagup & P(E_n | E_{n-1} \cap \dots \cap E_1) \\ & & \diagup & & \diagdown & & & & \diagdown \\ & & E_1 & & E_2 & & E_{n-1} & & E_n \end{array} \quad \text{Multiplikation des ganzen Astes}$$

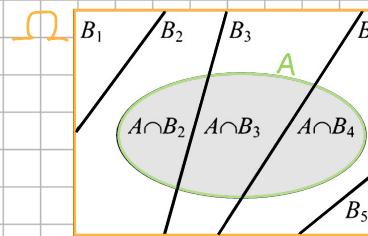
Gesetz d. totalen Wahrscheinlichkeit: Wklt mithilfe bed. Wklt

$$P(E) = \sum_{k=1}^n P(E|B_k) P(B_k)$$

$\Omega$  in disjunkte  $B_1, \dots, B_n$  aufteilen

$\Rightarrow B_1, \dots, B_n$  müssen 2 Bedingungen erfüllen:

- müssen paarweise disjunkt sein
- $B_1 \cup \dots \cup B_n = \Omega$  muss gelten

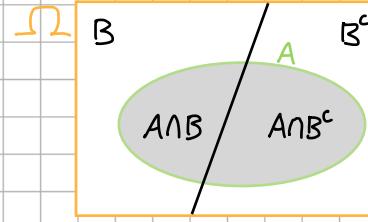


$$\begin{array}{l} P(B_1)(A) \quad A \\ P(B_1)(\bar{A}) \quad \bar{A} \\ P(B_2)(A) \quad A \\ P(B_2)(\bar{A}) \quad \bar{A} \\ \vdots \quad \vdots \\ P(B_n)(A) \quad A \\ P(B_n)(\bar{A}) \quad \bar{A} \end{array}$$

2 Teilmengen:

$$\begin{aligned} P(E) &= P(E \cap B) + P(E \cap B^c) \\ &= P(E|B) \cdot P(B) + P(E|B^c) \cdot P(B^c) \end{aligned}$$

hier wird  $\Omega$  in  $B$  und  $\bar{B}$  aufgeteilt



$$\begin{array}{l} P(B)(A) \quad A \\ P(B)(\bar{A}) \quad \bar{A} \\ P(\bar{B})(A) \quad A \\ P(\bar{B})(\bar{A}) \quad \bar{A} \end{array}$$

Satz von Bayes:  $P(B|A)$  mithilfe von  $P(A|B)$  berechnen

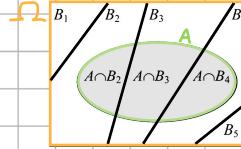
$$P(B|A) = \frac{P(B \cap A)}{P(A)} = \frac{P(A|B) P(B)}{P(A)}$$

Herleitung: Multiplikationsregel auf  $P(B \cap A)$  anwenden

mit totaler Wklt:

$$P(B_i|A) = \frac{P(B_i \cap A)}{P(A)} = \frac{P(A|B_i) P(B_i)}{\sum_{k=1}^n P(A|B_k) P(B_k)}$$

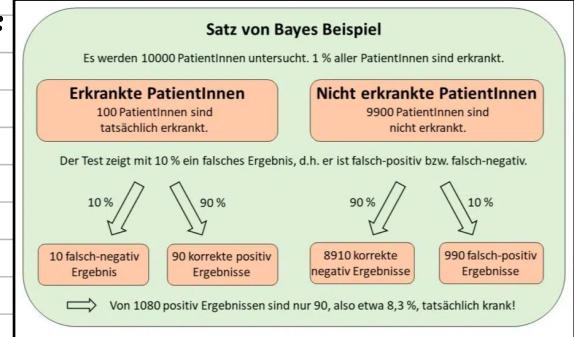
Herleitung: Gesetz d. tot. Wklt auf  $P(A)$  anwenden



2 Teilmengen:

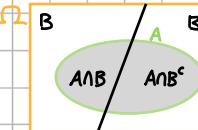
$$P(B|A) = \frac{P(A|B) P(B)}{P(A|B) P(B) + P(A|B^c) P(B^c)}$$

Bayes:



$$P(\text{krank}|\text{positiv}) = \frac{P(\text{positiv}|\text{krank}) \cdot P(\text{krank})}{P(\text{positiv})}$$

$$P(\text{krank}|\text{positiv}) = \frac{0,9 \cdot 0,01}{1080/10000} = \frac{0,9 \cdot 0,01}{0,1089} \sim 0,083 = 8,3 \%$$



# Discrete Zufallsvariablen

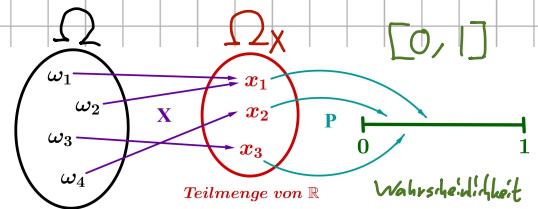
Zufallsvariable

$$X: \Omega \rightarrow \mathbb{R}$$

$$\omega \mapsto x$$

salopp: Größe, deren Wert vom Zufall abhängt

Funktion welche jedem Ergebnis  $\omega \in \Omega$  eine Zahl  $x \in \mathbb{R}$  zuweist  
 → manchmal auch  $\mathbb{R}^n$  anstatt  $\mathbb{R}$ , resp.  $\vec{x}$  anstatt  $x$ !



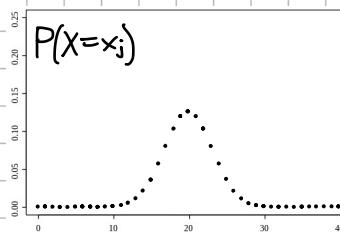
Wahrscheinlichkeitsfunktion EN: probability mass function (PMF)

$$p_X: \Omega_X \rightarrow [0, 1]$$

$$x_i \mapsto p_X(x_i) = P(X=x_i)$$

Funktion welche allen  $x_i \in \Omega_X$  die Wahrscheinlichkeit zuordnet dass die diskrete Zufallsvariable  $X$  diesen Wert  $x_i$  annimmt

$x_j$	$x_1$	$x_2$	$\dots$	$x_{m-1}$	$x_m$
$p_X(x_j)$	$P(X=x_1)$	$P(X=x_2)$	$\dots$	$P(X=x_{m-1})$	$P(X=x_m)$

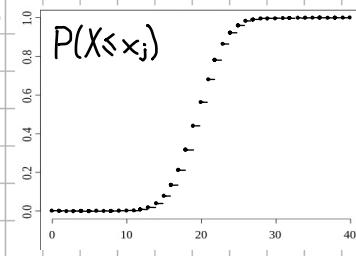


kumulierte Verteilungsfunktion EN: cumulative distribution function (CDF)

$$P(X \leq x_j) = \sum_{k=1}^j p_X(x_k)$$

Wahrscheinlichkeit, dass  $X$  einen Wert kleiner gleich  $x_j$  annimmt

$x_j$	$x_1$	$x_2$	$\dots$	$x_{m-1}$	$x_m$
$\sum_{k=1}^j p_X(x_k)$	$P(X \leq x_1)$	$P(X \leq x_2)$	$\dots$	$P(X \leq x_{m-1})$	$P(X \leq x_m) = 1$



## Unabhängigkeit

$X_1, \dots, X_n$  sind unabhängig, falls

$$\begin{aligned} p_{\vec{X}}(x_1, \dots, x_n) &= P(X_1=x_1 \text{ und } \dots \text{ und } X_n=x_n) \\ &= P(X_1=x_1) \cdots P(X_n=x_n) \\ &= p_{X_1}(x_1) \cdots p_{X_n}(x_n) \end{aligned}$$

für alle  $\vec{x}=(x_1, \dots, x_n) \in \Omega_{\vec{X}} = \Omega_{X_1} \times \dots \times \Omega_{X_n}$  gilt

Jede der Koordinatenfunktionen  $X_1, \dots, X_n$  einer diskreten, vektorwertigen Zufallsvariable

$$\mathbf{X} = \begin{pmatrix} X_1 \\ \vdots \\ X_n \end{pmatrix} \in \mathbb{R}^n$$

können wir als diskrete, reellwertige Zufallsvariable auffassen. Die Verteilung  $p_{\vec{X}}$  der diskreten, vektorwertigen Zufallsvariable  $\mathbf{X}$  enthält Zusammenhänge zwischen den Zufallsvariablen  $X_1, \dots, X_n$  und diese Zusammenhänge verlieren wir, wenn wir nur die Verteilungen  $p_{X_1}, \dots, p_{X_n}$  der einzelnen reellwertigen Zufallsvariablen betrachten. Wir werden diese Thematik später genauer studieren und uns an dieser Stelle auf einen wichtigen Spezialfall beschränken. Wenn keine zusätzliche Information in der Verteilung der vektorwertigen Zufallsvariable  $\mathbf{X}$  enthalten ist, nennen wir die Zufallsvariablen  $X_1, \dots, X_n$  unabhängig.

Erwartungswert  $\mu$  (Mü)

$$\mu = E[X] = \sum_{j=1}^m x_j \cdot p_X(x_j)$$

gewichtete Summe von allen möglichen  $x_j \in \Omega_X$ ,  
 wobei jeder Wert  $x_j$  mit seiner Wahrscheinlichkeit  
 $p_X(x_j)$  gewichtet wird

$$E[a_1 \cdot X_1 + a_2 \cdot X_2] = a_1 \cdot E[X_1] + a_2 \cdot E[X_2]$$

Linearität

$$E[f(X)] = \sum_{j=1}^m f(x_j) \cdot p_X(x_j)$$

$$E[X^2] = \sum_{j=1}^m x_j^2 \cdot p_X(x_j)$$

Varianz  $\sigma^2$

$$\sigma^2 = V[X] = \sum_{j=1}^m (x_j - \mu)^2 \cdot p_x(x_j)$$

gewichtete Summe der quadrierten Abweichungen vom Erwartungswert

$$V[X] = E[X^2] - (E[X])^2$$

oft hilfreich

$$V[aX + b] = a^2 \cdot V[X]$$

Standardabweichung  $\sigma$  (Sigma)

$$\sigma = \sqrt{V[X]} = \sqrt{\sum_{j=1}^m (x_j - \mu)^2 \cdot p_x(x_j)}$$

$$\sqrt{V[aX + b]} = |a| \cdot \sqrt{V[X]}$$

W'keit einer Abweichung von mehr als  $d > 0$  vom Erwartungswert

$$P(|X - E[X]| \geq d) \leq \frac{V[X]}{d^2}$$

Chobyshev-Ungleichung  
selten hilfreich

Rundengewinn  $\rightarrow$  SGA 6

$$P(\text{zuerst } n \text{ Runden}) = \sum_{k=0}^{n-1} \binom{n+k-1}{n-1} p^n (1-p)^k$$

Wer zuerst in Runden gewinnt, gewinnt das Turnier  
 $p$  = W'keit eine einzelne Runde zu gewinnen

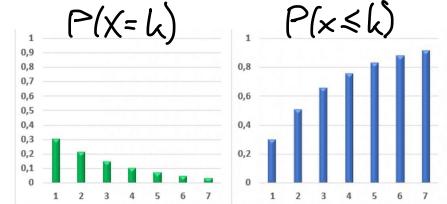
# Diskrete Verteilungen

## Geometrische Verteilung

Anzahl Versuche bis zum ersten Erfolg bei konstanter Erfolgswahrscheinlichkeit  $p$ . Beispiel: Kugeln ziehen *mit* zurücklegen, von den Kugeln ist ein Anteil  $p$  rot, Erfolg = eine rote.

### Parameter

- $p$ : Erfolgswahrscheinlichkeit

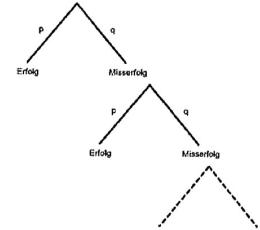


erster Erfolg beim  $k$ -ten Versuch:  $P(X = k) = p \cdot (1 - p)^{k-1}$

erster Erfolg nach nicht mehr als  $k$  Versuchen:  $P(X \leq k) = 1 - (1 - p)^k$

$$E(X) = 1/p$$

$$\sigma^2(X) = (1 - p)/p^2$$

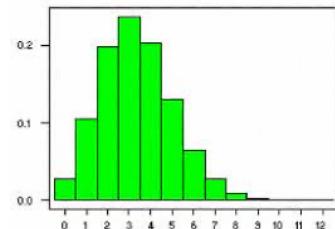


## Binomische Verteilung

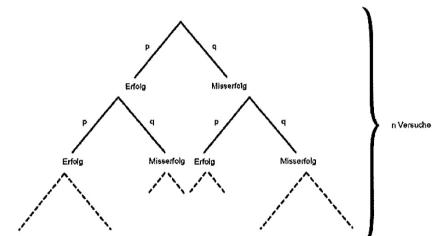
Anzahl Erfolge in  $n$  Versuchen mit konstanter Wahrscheinlichkeit  $p$ . Beispiel: Kugeln ziehen *mit* zurücklegen, von den Kugeln ist ein Anteil  $p$  rot, Erfolg = eine rote

### Parameter

- $p$ : Erfolgswahrscheinlichkeit
- $n$ : Anzahl Versuche



$$\begin{aligned} P(X = k) &= \binom{n}{k} \cdot p^k \cdot (1 - p)^{n-k} \\ E(X) &= n \cdot p \\ \sigma^2(X) &= n \cdot p \cdot (1 - p) \end{aligned}$$



$$P(X \leq l) = \sum_{k=0}^l \binom{n}{k} p^k \cdot (1 - p)^{n-k} \rightarrow \text{S1A3 (Bakterien), S1A5 (Plantage)}$$

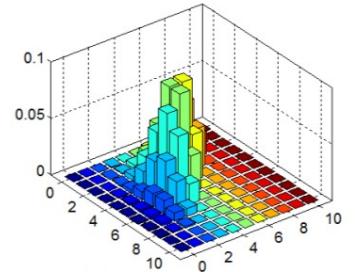
$$P(X \geq l) = \sum_{k=l}^n \binom{n}{k} p^k \cdot (1 - p)^{n-k} \rightarrow \text{S1A7}$$

## Multinomische Verteilung $\rightarrow 5647$

Anzahl Ergebnisse vom Typ  $1, 2, \dots, k$ , welche konstante Wahrscheinlichkeiten  $p_1, p_2, \dots, p_k$  haben,  $n$  Versuchen. Beispiel: Anzahl Würfe mit Augenzahl  $1, 2, \dots, 6$  in  $n$  unabhängigen Würfeln eines Würfels.

### Parameter

- $p_1, \dots, p_k$ : Erfolgswahrscheinlichkeiten
- $n$ : Anzahl Versuche



$$\begin{aligned} P(n_1, n_2, \dots, n_k) &= \binom{n}{n_1 n_2 \dots n_k} \cdot p_1^{n_1} \cdot \dots \cdot p_k^{n_k} \\ &= \frac{n!}{n_1! \cdot n_2! \cdot \dots \cdot n_k!} \cdot p_1^{n_1} \cdot \dots \cdot p_k^{n_k} \end{aligned}$$

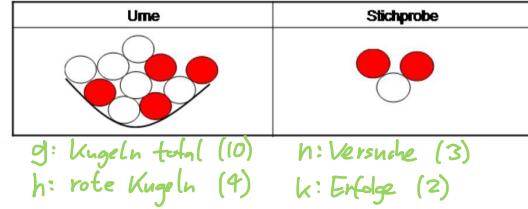
Wobei  $n = n_1 + \dots + n_k$

## Hypergeometrische Verteilung $\rightarrow$ S6A8

Anzahl Erfolge in  $n$  Versuchen, ohne zurücklegen. Beispiel:  $n$  Kugeln ziehen aus  $g$  Kugeln, von denen  $h$  rot sind. Erfolg = eine rote

### Parameter

- $g$ : Anzahl Kugeln
- $h$ : Anzahl rote Kugeln
- $n$ : Anzahl Versuche



$$P(X = k) = \frac{\binom{h}{k} \cdot \binom{g-h}{n-k}}{\binom{g}{n}}$$

Wahrsch.  $k$  (2) rote Kugeln zu erhalten wenn man  $n$  (3) Kugeln aus einer Urne zieht in welcher  $g$  (10) Kugeln liegen, davon  $h$  (4) rot sind

$$E(X) = n \cdot \frac{h}{g}$$

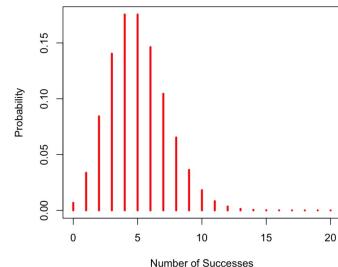
$$\sigma^2(X) = n \cdot \frac{h}{g} \cdot \left(1 - \frac{h}{g}\right) \cdot \frac{g-n}{g-1}$$

## Poisson Verteilung $\rightarrow$ S6A9, S6A10

Anzahl Ereignisse pro Zeiteinheit, wenn der Mittelwert (Erwartungswert) der Ereignisse bekannt ist und die Ereignisse unabhängig voneinander eintreten. Beispiel: Anzahl radioaktiver Zerfälle / Sekunde, Anzahl Kunden, die pro Stunde am Postschalter eintreffen

### Parameter

- $\lambda$  Erwartungswert (= Varianz)



$$P(X = k) = e^{-\lambda} \cdot \frac{\lambda^k}{k!}$$

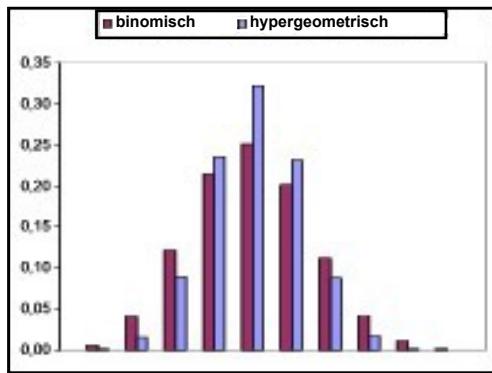
$$E(X) = \lambda$$

$$\sigma^2(X) = \lambda$$

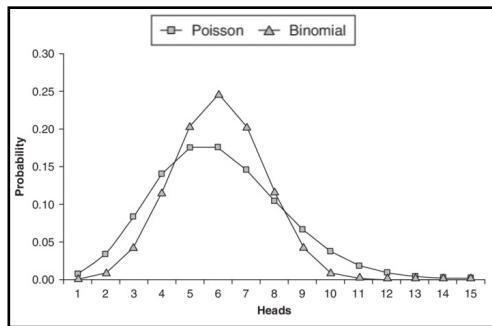
## Näherungen

Verteilung 1	Parameter	Verteilung 2	Parameter	Bedingung
hypergeometrisch	$g, h, n$	binomisch	$n = n, p = h/g$	$h \ll g$
binomisch	$n, p$	Poisson	$\lambda = n \cdot p$	$p \ll 1$

→ S6A8  
→ S6A9, S6A10



Aus einer Urne mit roten und blauen Kugeln werden 10 Kugeln gezogen.  
Zufallsgröße X ist die Zahl der gezogenen roten Kugeln.  
a) Ziehen mit Zurücklegen. Die Grundwahrscheinlichkeit ändert sich nicht.  
Die Wahrscheinlichkeiten sind binomial verteilt.  
b) Ziehen ohne Zurücklegen. Die Grundwahrscheinlichkeit ändert sich.  
Die Wahrscheinlichkeiten sind hypergeometrisch verteilt.



Poisson versus binomial distribution, from number of heads in a coin toss. The Poisson distribution shown assumes an average of 5 heads per toss ( $\lambda = 5$ ); the binomial distribution shown assumes 10 coins were tossed, and the probability of a head is 0.5.

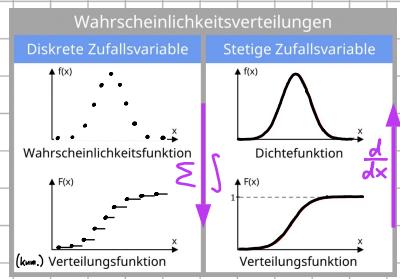
# Stetige Zufallsvariablen

## Dichtefunktion

$$f(x) = \frac{d}{dx} F(x)$$

$\rightarrow$  S7A1, S7A2

EN: probability density function (PDF)  
analog zu Wahrscheinlichkeitsfunktion bei diskret



Verteilungsfunktion EN: cumulative distribution function (CDF)  
analog zu kumulierten Verteilung bei diskret

$$F(x) = \int_{-\infty}^x f(t) dt = P(X \leq x)$$

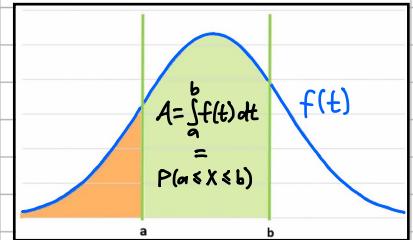
Wahrscheinlichkeit, dass  $X$  einen Wert kleiner gleich  $x$  annimmt

$$\int_{-\infty}^{\infty} f(t) dt = 1 \rightarrow \text{S7A3}$$

$$P(X=x) = \int_x^x f(t) dt = 0$$

$$P(a \leq X \leq b) = P(X \leq b) - P(X \leq a) = F(b) - F(a) = \int_a^b f(t) dt$$

$$P(X > x) = 1 - P(X \leq x) = 1 - F(x)$$



## Quantile

$$p\text{-Quantil } x_p: x_p = F^{-1}(p)$$

## Median

$$\text{Median } a = x_{\frac{1}{2}}: a = F^{-1}(0.5) \neq E[X]$$

(0.5-Quantil)

## Erwartungswert $\mu$ (Mü)

$$\mu = E[X] = \int_{-\infty}^{\infty} t \cdot f(t) dt$$

$$E[a_1 \cdot X_1 + a_2 \cdot X_2] = a_1 \cdot E[X_1] + a_2 \cdot E[X_2]$$

Linearität

$$E[r(X)] = \int_{-\infty}^{\infty} r(t) \cdot f(t) dt$$

M einer transformierten Zufallsvariablen

$$E[X^2] = \int_{-\infty}^{\infty} t^2 \cdot f(t) dt$$

## Varianz $\sigma^2$

$$\sigma^2 = V[X] = \int_{-\infty}^{\infty} (t - \mu)^2 \cdot f(t) dt$$

$$V[X] = E[X^2] - (E[X])^2$$

oft hilfreich!

$$V[aX + b] = a^2 \cdot V[X]$$

## Standardabweichung $\sigma$

$$\sigma = \sqrt{V[X]} = \sqrt{\int_{-\infty}^{\infty} (t - \mu)^2 \cdot f(t) dt}$$

$$\sqrt{V[aX + b]} = |a| \cdot \sqrt{V[X]}$$

W'keit einer Abweichung von mehr als  $d > 0$  vom Erwartungswert

$$P(|X - E[X]| \geq d) \leq \frac{V[X]}{d^2}$$

Chabyshev-Ungleichung  
selten hilfreich

# Stetige Verteilungen

## Gleichverteilung/Uniformverteilung

Eine **auf dem Intervall  $(a, b)$  gleichverteilte** Zufallsvariable  $X$  ist absolut stetig und hat die Verteilungsfunktion und Dichte

$$F_X(x) = \begin{cases} 0 & \text{falls } x \leq a \\ \frac{x-a}{b-a} & \text{falls } a < x \leq b \\ 1 & \text{falls } b < x \end{cases} \quad \text{und } f(x) = \begin{cases} 0 & \text{falls } x \leq a \\ \frac{1}{b-a} & \text{falls } a < x \leq b \\ 0 & \text{falls } b < x \end{cases}$$

Wir haben den Erwartungswert und die Varianz

$$E[X] = \frac{a+b}{2} \quad \text{und} \quad \text{var}(X) = \frac{(b-a)^2}{12}$$

berechnet.

*W'keit berechnen*

### Lösen mit Dichtefunktion

$$P[u \leq X \leq v] = \int_u^v f(x) dx$$

$$P[X \geq u] = \int_u^{\infty} f(x) dx$$

$$P[X \leq v] = \int_{-\infty}^v f(x) dx$$

Zu beachten:  $f(x)$  ist nicht für alle  $x$  gleich!!!

Ausserhalb des Intervalls  $[a, b]$  gilt  $f(x) = 0$

### Lösen mit Verteilungsfunktion

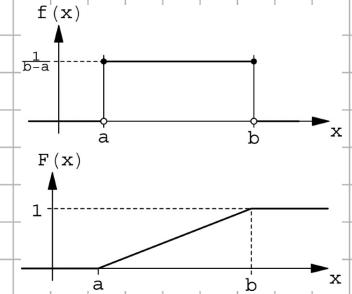
$$P[u \leq X \leq v] = F(v) - F(u)$$

$$P[X \geq u] = 1 - F(u)$$

$$P[X \leq v] = F(v)$$

Zu beachten:  $F(x)$  ist nicht für alle  $x$  gleich!!!

Für  $x < a$  gilt  $F(x) = 0$ , für  $x > b$  gilt  $F(x) = 1$



## Exponentialverteilung

Die Exponentialverteilung wird häufig verwendet, um die Wartezeiten zwischen Ereignissen zu modellieren (Zeit zwischen Anrufen auf Hotline, Zeit zwischen ankommen Kunden, Zeit zwischen dem Ausfall von Glühbirnen eines Gebäudes, ...) und kann als nicht diskrete Version der geometrischen Verteilung aufgefasst werden.<sup>20)</sup>

Eine **exponentiell mit der Rate  $\lambda > 0$  verteilte** Zufallsvariable hat die Verteilungsfunktion und Dichte

$$F_X(x) = \begin{cases} 1 - e^{-\lambda x} & \text{falls } x > 0 \\ 0 & \text{sonst} \end{cases} \quad \text{und } f_X(x) = \begin{cases} \lambda e^{-\lambda x} & \text{falls } x > 0 \\ 0 & \text{sonst} \end{cases}$$

Mittels partieller Integration können der Erwartungswert und die Varianz

$$E[X] = \frac{1}{\lambda} \quad \text{und} \quad \text{var}(X) = \frac{1}{\lambda^2}$$

berechnet werden. (Darstellung 7)

Eine wichtige Eigenschaft der Exponentialverteilung ist die sogenannte **Gedächtnislosigkeit**. Für jede exponentiell mit Rate  $\lambda$  verteilten Zufallsvariable  $X$  und beliebige Werte  $x, d > 0$  gilt die Gleichung

$$P(X > x + d | X > x) = P(X > d) \rightarrow S8A1, S8A2$$

In Worten: Wenn wir schon  $x$  Zeiteinheiten gewartet haben, dann ist die Wahrscheinlichkeit, noch einmal mindestens  $d$  Zeiteinheiten warten zu müssen die gleiche, wie wenn wir überhaupt noch nicht gewartet hätten.

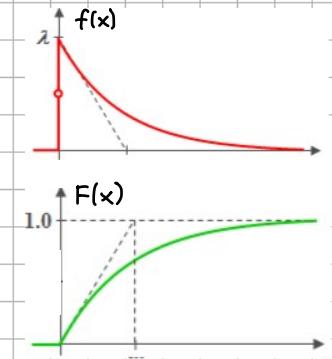
*W'keit berechnen*

### Lösen mit Dichtefunktion

$$\begin{aligned} P[a \leq X \leq b] &= \int_a^b f(x) dx \\ &= \int_a^b \lambda e^{-\lambda x} dx = [-e^{-\lambda x}]_a^b \end{aligned}$$

### Lösen mit Verteilungsfunktion

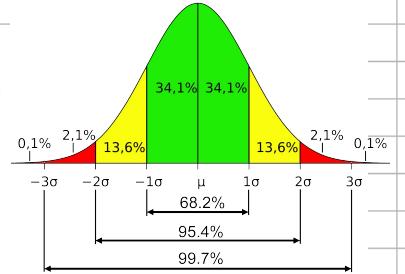
$$\begin{aligned} P[a \leq X \leq b] &= F(b) - F(a) \\ &= (1 - e^{-\lambda b}) - (1 - e^{-\lambda a}) \\ &= e^{-\lambda a} - e^{-\lambda b} \end{aligned}$$



# Normalverteilung/Gaussverteilung

Wir betrachten in diesem Abschnitt die sogenannte Normal- oder Gaussverteilung, welche die wahrscheinlich wichtigste aller Verteilungen ist. Eine **normalverteilte Zufallsvariable**  $X$  besitzt die Dichte

$$f_X(x) = \frac{1}{\sqrt{2\pi}\sigma^2} e^{-\frac{(x-\mu)^2}{2\sigma^2}} = \mathcal{N}_{\mu,\sigma}(x) \quad \text{TR: normPdf(x, \mu, \sigma)}$$



mit dem Mittelwert  $\mu \in \mathbb{R}$  und der Standardabweichung  $\sigma > 0$ . Die Bezeichnung der Parameter ist gerechtfertigt, denn mittels Rechnung erhalten wir den Erwartungswert und die Varianz

$$E[X] = \mu \text{ und } \text{var}(X) = \sigma^2.$$

Die Verteilungsfunktion

$$F_X(x) = \int_{-\infty}^x f_X(t) dt = \Phi_{\mu,\sigma}(x) \quad \text{TR: normCdf(-∞, x, \mu, \sigma)}$$

kann leider nicht geschlossen integriert werden<sup>21</sup>. Eine Darstellung als Potenzreihe ist jedoch möglich und für die numerische Berechnung der Werte werden geeignete Approximationstechniken verwendet.

Da die Dichte  $f_X(x)$  der Normalverteilung symmetrisch um den Mittelwert  $\mu$  liegt, erhalten wir für die Verteilungsfunktion die Beziehung

$$F_X(\mu - x) = 1 - F_X(\mu + x)$$

Die Bedeutung der Normalverteilung ergibt sich aus dem zentralen Grenzwertsatz, welcher vereinfachend formuliert besagt<sup>22</sup>, dass jede Summe von vielen kleinen und untereinander unabhängigen Beiträgen annähernd normalverteilt ist<sup>23</sup>. Wir werden diesen Grenzwertsatz im Kapitel 5 studieren.

In vielen Quellen finden wir die Werte der Verteilungsfunktion

$$\Phi(x) = \Phi_{0,1}(x) = \frac{1}{\sqrt{2\pi}} \int_{-\infty}^x e^{-\frac{t^2}{2}} dt$$

der sogenannten **Standard-Normalverteilung**, also der Normalverteilung mit den Parametern  $\mu = 0$  und  $\sigma = 1$ , in Tabellenform<sup>24</sup>. Daraus können wir bei Bedarf die Werte der Verteilungsfunktion der allgemeinen Normalverteilung berechnen, denn für jede normalverteilte Zufallsvariable  $X$  und jede Zahl  $x \in \mathbb{R}$  erhalten wir mittels der Integraltransformation  $t = \sigma s + \mu = g(s)$  die Verteilungsfunktion

$$\begin{aligned} \Phi_{\mu,\sigma}(x) = F_X(x) &= P(X \leq x) = \frac{1}{\sqrt{2\pi}\sigma^2} \int_{-\infty}^x e^{-\frac{(t-\mu)^2}{2\sigma^2}} dt \\ &= \frac{1}{\sqrt{2\pi}} \int_{-\infty}^{\frac{x-\mu}{\sigma}} e^{-\frac{s^2}{2}} ds = \Phi\left(\frac{x-\mu}{\sigma}\right). \end{aligned} \quad \rightarrow \text{S10A11}$$

Für eine beliebige normalverteilte Zufallsvariable  $X$  und einen Wert  $k \in \mathbb{R}$  ist die Wahrscheinlichkeit, dass der Wert der Zufallsvariable  $X$  um weniger als  $k$  Standardabweichungen  $\sigma$  vom Mittelwert  $\mu$  abweicht

$$\begin{aligned} P(\mu - k\sigma \leq X \leq \mu + k\sigma) &= F_X(\mu + k\sigma) - F_X(\mu - k\sigma) \\ &= 2F_X(\mu + k\sigma) - 1 = 2\Phi(k) - 1, \end{aligned} \quad \rightarrow \text{S8A5}$$

immer die gleiche.

$$P(\mu - \sigma \leq X \leq \mu + \sigma) \cong 0.683$$

$$P(\mu - 2\sigma \leq X \leq \mu + 2\sigma) \cong 0.955$$

$$P(\mu - 3\sigma \leq X \leq \mu + 3\sigma) \cong 0.997$$

⋮

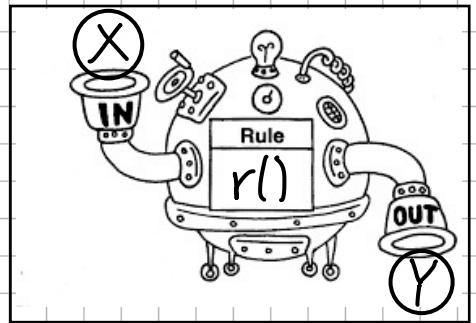
Bei der Berechnung der  $p$ -Quantilen  $x_p$  kommt die inverse Funktion der Verteilungsfunktion  $F_X$  oder die inverse der Standard-Normal-Verteilungsfunktion  $\Phi$  zum Einsatz.

# Transformation von Zufallsvariablen

Notation & Definition:

$Y$  ist die transformierte Zufallsvariable, die aus  $X$  durch Anwenden der Funktion  $r: \mathbb{R} \rightarrow \mathbb{R}$  entsteht:

$$r(X) = Y$$



Dichte funktion von  $Y$

falls  $P(a < X < b) = 1$  und  $r: (a, b) \rightarrow (c, d)$  dann hat  $Y = r(X)$  die Dichte

$$f_Y(y) = \begin{cases} f_X(s(y)) \left| \frac{d}{dy} s(y) \right| & c < y < d \\ 0 & \text{sonst} \end{cases}$$

$s(y) = r^{-1}(y)$  Umkehrfunktion  
 $\rightarrow r(x) = y$  nach  $x$  auflösen

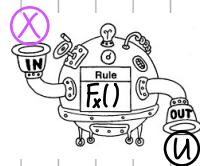
→ SGAZ-6

2 nützliche Spezialfälle

Wenn man eine beliebige Zufallsvariable  $X$  mit ihrer Verteilungsfunktion  $F_X$  transformiert, ist die daran entstehende Zufallsvariable  $Y = F_X(X)$  gleichverteilt auf dem Intervall  $(0, 1)$ :

$$F_X(X) = U$$

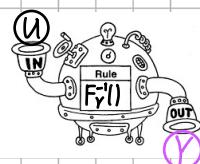
$X$  beliebig  
 $r = F_X$   
 $Y = U$



Wenn man umgekehrt eine auf  $(0, 1)$  gleichverteilte Zufallsvariable  $X$  mit der Umkehrfunktion  $F_Y^{-1}$  einer beliebigen Verteilungsfunktion  $F_Y$  transformiert, hat die daran entstehende Zufallsvariable  $Y = F_Y^{-1}(X)$  die Verteilungsfunktion  $F_Y$

$$F_Y^{-1}(U) = Y$$

$X = U$   
 $r = F_Y^{-1}$   
 $Y$  beliebig



→ Zufallszahlengenerator mit beliebiger Verteilung

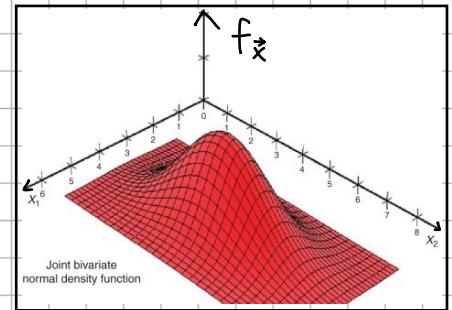
→ SGA1

# Mehrdimensionale Zufallsvariablen

verdeutlichte Zufallsvariable:  $\vec{X} = \begin{pmatrix} X_1 \\ \vdots \\ X_n \end{pmatrix}$

## gemeinsame Dichte

$$f_{\vec{X}} : \mathbb{R}^n \rightarrow [0, \infty) \\ \vec{t} \mapsto f_{\vec{X}}(\vec{t}) = f_{\vec{X}}(t_1, \dots, t_n) = \frac{\partial^n F(x_1, \dots, x_n)}{\partial x_1 \cdots \partial x_n}$$



gemeinsame Verteilung  $\int_{-\infty}^{x_1} \cdots \int_{-\infty}^{x_n} f_{\vec{X}}(t_1, \dots, t_n) dt_1 \cdots dt_n$

$$F_{\vec{X}} : \mathbb{R}^n \rightarrow [0, 1] \\ \vec{x} \mapsto F_{\vec{X}}(\vec{x}) = F_{\vec{X}}(x_1, \dots, x_n) = \int_{-\infty}^{x_1} \cdots \int_{-\infty}^{x_n} f_{\vec{X}}(t_1, \dots, t_n) dt_1 \cdots dt_n$$

$$P(X_1 \leq x_1 \wedge \dots \wedge X_n \leq x_n) = F_{\vec{X}}(x_1, \dots, x_n)$$

$\rightarrow$  S10 A2

## Wahrscheinlichkeit für Ereignis $A \subset \mathbb{R}^n$

$$P(\vec{X} \in A) = \int_A f_{\vec{X}}(\vec{t}) d\vec{t} \quad \rightarrow$$

Normierung:

$$P(\vec{X} \in \mathbb{R}^n) = \int_{\mathbb{R}^n} f_{\vec{X}}(\vec{t}) d\vec{t} \stackrel{!}{=} 1 \quad \rightarrow$$

Annäherung für kleines, an Stelle  $\vec{x}_0$  zentriertes  $A_{\vec{x}}$ :

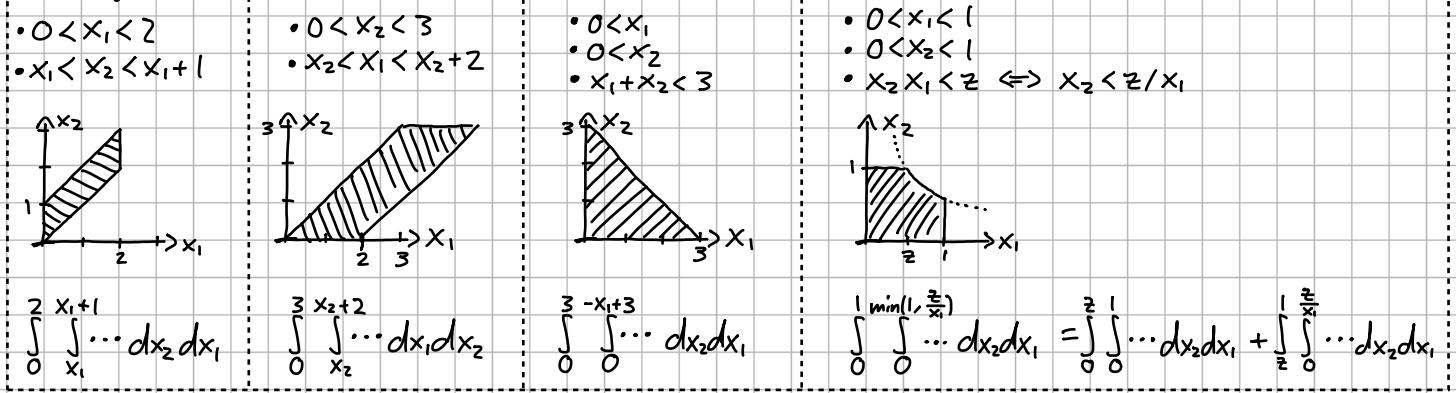
$$P(\vec{X} \in A_{\vec{x}_0}) = \int_{A_{\vec{x}_0}} f_{\vec{X}}(\vec{t}) d\vec{t} \approx \text{Vol}_n(A_{\vec{x}_0}) \cdot f_{\vec{X}}(\vec{x}_0)$$

$\hat{=}$  «Grundfläche · Höhe» falls  $n=2$

## Integralgrenzen finden

1. Grenzen des Ereignisses  $A$  bestimmen/skizzieren
2. Bereich finden/skizzieren wo  $f_{\vec{X}}(\vec{x}) \neq 0$  ist  
 $\rightarrow$  überall wo  $f_{\vec{X}}(\vec{x}) = 0$  ist, ist auch Integral davon 0
3. Schnittmenge davon bilden (Bedingungen aus 1. und 2. kombinieren)
4. Integrationsreihenfolge bestimmen:
  - 4.1 äußere Integralgrenzen müssen konstant sein
  - 4.2 innere Grenzen dürfen Funktionen der äußeren Variablen sein  
 $\rightarrow$  bei Eck- / Sprüngen Integral aufteilen mit verschiedenen Funktionen  $\rightarrow$  S9 A9

## Häufige Situationen:



## Randverteilung

gegeben: Zufallsvektor  $\vec{X} = \begin{pmatrix} X_1 \\ \vdots \\ X_n \end{pmatrix}$  mit gemeinsamer Dichte  $f_{\vec{X}}(\vec{t}) = f_{\vec{X}}(t_1, \dots, t_n)$

Rand-Dichte funktion  $\rightarrow$  S9A10/11

$$f_{X_k}(x_k) = \int_{-\infty}^{\infty} \cdots \int_{-\infty}^{\infty} f_{\vec{X}}(t_1, \dots, t_{k-1}, x_k, t_{k+1}, \dots, t_n) dt_1 \cdots dt_{k-1} dt_{k+1} \cdots dt_n$$

$\rightarrow$  Grenzen dürfen  $x_k$  enthalten

Integral über alle anderen Komponenten

Rand-Verteilungsfunktion

$$F_{X_k}(x_k) = \int_{-\infty}^{x_k} f_{X_k}(t_k) dt_k$$

Erwartungswert

$$E[\vec{X}] = \begin{pmatrix} E[X_1] \\ \vdots \\ E[X_n] \end{pmatrix} = \begin{pmatrix} \int_{-\infty}^{\infty} t_1 f_{X_1}(t_1) dt_1 \\ \vdots \\ \int_{-\infty}^{\infty} t_n f_{X_n}(t_n) dt_n \end{pmatrix}$$

Erwartungswerte Komponentenweise mithilfe der Rand-Dichte berechnen

Unabhängigkeit

Definition:

$$X_1, \dots, X_n \text{ sind unabhängig } \Leftrightarrow f_{\vec{X}}(\vec{x}) = f_{X_1}(x_1) \cdots f_{X_n}(x_n)$$

$\rightarrow$  S10A2-6

gemeinsame Dichte  
= Produkt der Rand-Dichten

gleiches gilt auch für Verteilung  $\Rightarrow$  falls  $X_1, \dots, X_n$  unabhängig, gilt also:

$$f_{\vec{X}}(\vec{x}) = f_{X_1}(x_1) \cdots f_{X_n}(x_n)$$

$$F_{\vec{X}}(\vec{x}) = F_{X_1}(x_1) \cdots F_{X_n}(x_n)$$

Verteilung von  $X_{\max} = \max(X_1, \dots, X_n)$  und  $X_{\min} = \min(X_1, \dots, X_n)$  von  $n$  unabhängigen und gleich verteilten (nicht im Sinne von Uniformverteilung!) Zufallsvariablen  $X_1, \dots, X_n$  mit der Verteilungsfunktion  $F_X$ :

$$\begin{aligned} F_{X_{\max}}(x) &= P(\max(X_1, \dots, X_n) \leq x) = P(X_1 \leq x \wedge \dots \wedge X_n \leq x) \\ &= P(X_1 \leq x) \cdots P(X_n \leq x) \\ &= (F_X(x))^n \end{aligned}$$

$$\begin{aligned} F_{X_{\min}}(x) &= P(\min(X_1, \dots, X_n) \leq x) = 1 - P(\min(X_1, \dots, X_n) > x) = 1 - P(X_1 > x \wedge \dots \wedge X_n > x) \\ &= 1 - P(X_1 > x) \cdots P(X_n > x) \\ &= 1 - (1 - F_X(x))^n \end{aligned}$$

$\rightarrow$  S10A2/A9.2, S13A1.3

bedingte Dichte von  $X_1$ , gegeben  $X_2$   $\rightarrow$  S10A7/8

$$f_{X_1}(x_1 | X_2 = x_2) = \frac{f_{\vec{X}}(x_1, x_2)}{f_{X_2}(x_2)} = \frac{f_{\vec{X}}(x_1, x_2)}{\int_{-\infty}^{\infty} f_{\vec{X}}(t_1, x_2) dt_1}$$

## Summen unabhängiger Zufallsvariablen

gegeben: Summe  $Y = X_1 + X_2$  von 2 unabh. Zufallsvariablen

Wahrscheinlichkeitsfunktion (diskrete  $X_1, X_2$ )

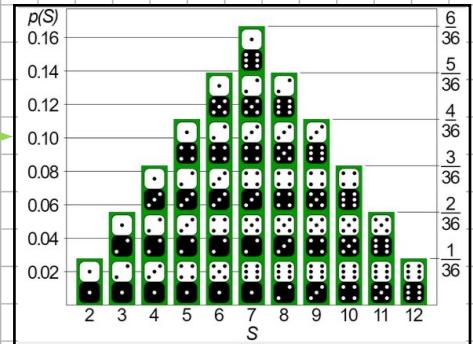
$$p_Y(y) = \sum_x p_{X_1}(x) \cdot p_{X_2}(y-x)$$

diskrete Faltung

Dichtefunktion (stetige  $X_1, X_2$ )

$$f_Y(y) = \int_{-\infty}^{\infty} f_{X_1}(x) \cdot f_{X_2}(y-x) dx$$

Faltung



## Exponentialverteilung

Summe von  $n$  unabhängigen, mit dem Parameter  $\lambda$  exponentiell verteilten Zufallsvariablen:

$$f_X(x) = \begin{cases} \frac{\lambda^n x^{n-1}}{(n-1)!} e^{-\lambda x} & \text{falls } x > 0 \\ 0 & \text{sonst} \end{cases}$$

gammaverteilt mit Parameter  $(n, \lambda)$

→ SIIA1

## Normalverteilung

Summe von  $n$  unabhängigen, mit den Parametern  $(\mu_i, \sigma_i)$  normalverteilten Zufallsvariablen  $X_1, \dots, X_n$  ist wieder normalverteilt mit Parametern  $\tilde{\mu}$  und  $\tilde{\sigma}^2$ :

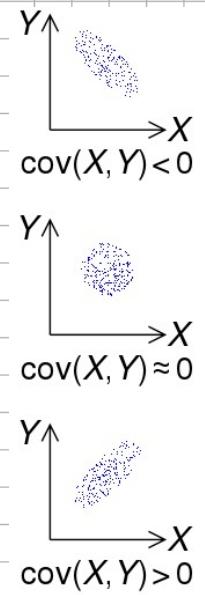
$$Y = \sum_{i=1}^n X_i \sim \text{Normal}(\tilde{\mu}, \tilde{\sigma}^2) \quad \text{mit} \quad \tilde{\mu} = \sum_{i=1}^n \mu_i \quad \text{und} \quad \tilde{\sigma}^2 = \sqrt{\sum_{i=1}^n \sigma_i^2}$$

→ SIOA1

# Kovarianz, Varianz, Korrelation

## Kovarianz

$$\text{cov}(X_1, X_2) = \begin{cases} \sum_{x_1} \sum_{x_2} (x_1 - \mu_1)(x_2 - \mu_2) p_{\tilde{X}}(x_1, x_2) & \text{diskret} \\ \int_{\mathbb{R}} \int_{\mathbb{R}} (x_1 - \mu_1)(x_2 - \mu_2) f_{\tilde{X}}(x_1, x_2) dx_1 dx_2 & \text{stetig} \end{cases}$$



$$\text{cov}(X_1, X_2) = E[X_1 X_2] - E[X_1] E[X_2] \quad \text{oft hilfreich} \rightarrow \text{SIIA2/4}$$

$$\text{cov}(X_1, X_2) = \text{cov}(X_2, X_1)$$

$$\text{cov}(aX_1 + b\tilde{X}_1, X_2) = a \text{cov}(X_1, X_2) + b \text{cov}(\tilde{X}_1, X_2) \rightarrow \text{SIIA3/5}$$

## Korrelationskoeffizient

$$\rho_{X_1, X_2} = \text{cov}\left(\frac{X_1}{\sigma_1}, \frac{X_2}{\sigma_2}\right) = \frac{\text{cov}(X_1, X_2)}{\sigma_1 \sigma_2} \in (-1, 1) \rightarrow \text{SIIA2}$$

$$X_1 \text{ und } X_2 \text{ unabhängig} \Leftrightarrow \text{cov}(X_1, X_2) = 0, \quad \rho_{X_1, X_2} = 0$$

unabhängig  $\Rightarrow$  unkorreliert,  
aber nicht umgekehrt

## Varianz

$$\text{var}(X) = \text{cov}(X, X)$$

Summe  $X_1, \dots, X_n$  von  $n$  Zufallsvariablen:

$$\text{var}\left(\sum_{k=1}^n X_k\right) = \sum_{i=1}^n \sum_{j=1}^n \text{cov}(X_i, X_j) \rightarrow \text{SIIA5/6}$$

bei paarweiser Unkorreliertheit vereinfacht sich die Summe zu:

$$\text{var}\left(\sum_{k=1}^n X_k\right) = \sum_{k=1}^n \text{var}(X_k)$$

Summe von 2 Zufallsvariablen:

$$\text{var}(X_1 + X_2) = \text{var}(X_1) + 2\text{cov}(X_1, X_2) + \text{var}(X_2)$$

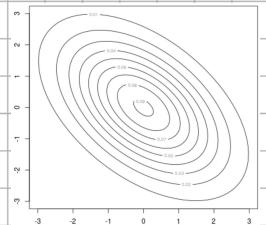
## Kovarianzmatrix

$$\Sigma = \begin{pmatrix} \text{cov}(X_1, X_1) & \dots & \text{cov}(X_1, X_n) \\ \vdots & \ddots & \vdots \\ \text{cov}(X_n, X_1) & \dots & \text{cov}(X_n, X_n) \end{pmatrix}$$

## mehrdimensionale Normalverteilung

tritt im Kontext von mehrdimensionalen Systemen sehr häufig auf

auch in  $n$  Dimensionen ist diese Verteilung vollständig durch Mittelpunkt und symmetrische Kovarianzmatrix bestimmt



ein  $n$ -dimensionaler normalverteilter Zufallsvektor  $\vec{X}$  hat eine Dichte der Form

$$f_{\vec{X}}(\vec{x}) = \frac{1}{(2\pi)^{\frac{n}{2}}} \frac{1}{(\det(\Sigma))^{\frac{1}{2}}} \exp\left(-\frac{1}{2}(\vec{x} - \vec{\mu})^T \Sigma^{-1} (\vec{x} - \vec{\mu})\right) = N_{\vec{\mu}, \Sigma}(\vec{x})$$

für die Situation  $n=1$  erhält man mit der Varianz  $\Sigma = \sigma^2$  die bekannte Gauss-Dichte

$$f_X(x) = \frac{1}{(2\pi)^{\frac{1}{2}}} \frac{1}{(\sigma^2)^{\frac{1}{2}}} \exp\left(-\frac{1}{2}(x - \mu)(\sigma^2)^{-1}(x - \mu)\right) = \frac{1}{\sqrt{2\pi\sigma^2}} \exp\left(-\frac{(x-\mu)^2}{2\sigma^2}\right) = N_{\mu, \sigma}(x)$$

der Ausdruck  $(\vec{x} - \vec{\mu})^T \Sigma^{-1} (\vec{x} - \vec{\mu})$  ist eine quadratische Form und misst das Quadrat der durch  $\Sigma$  definierten Distanz zwischen  $\vec{x}$  und  $\vec{\mu}$ , wobei für  $\Sigma = \mathbb{E}n$  genau die euklidische Distanz resultiert

somit ist die Dichte  $f_{\vec{X}}(\vec{x})$  konstant auf der Menge aller Punkte  $S_d = \{\vec{x} \in \mathbb{R}^n \mid (\vec{x} - \vec{\mu})^T \Sigma^{-1} (\vec{x} - \vec{\mu}) = d^2\}$ , welche die Distanz  $d$  zum Mittelpunkt haben

diese Mengen  $S_d$  sind Ellipsoide mit denselben im Mittelpunkt  $\vec{\mu}$  zentrierten Hauptachsen

# Grenzwertsätze

i.i.d. (independent and identically distributed):

Zufallsvariablen  $X_1, X_2, \dots, X_n$ , welche unabhängig sind und dieselbe Verteilung haben

Summe von i.i.d. Zufallsvariablen  $S_n$

$$S_n = X_1 + \dots + X_n \quad \text{neue Zufallsvariable}$$

Mittelwert einer i.i.d. Folge

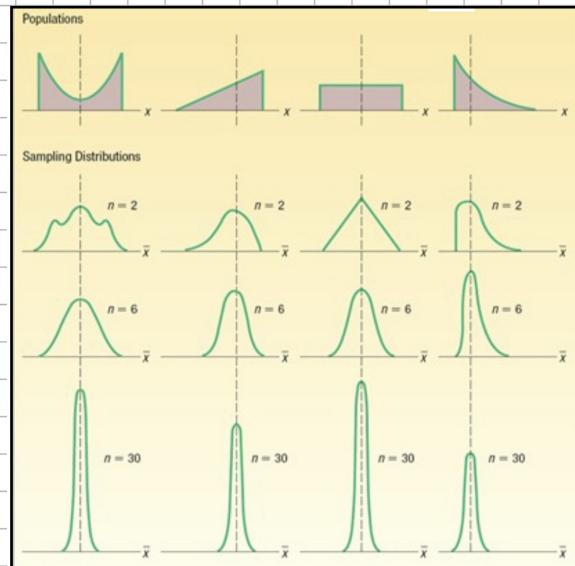
$$\bar{X}_n = \frac{X_1 + \dots + X_n}{n} = \frac{S_n}{n}$$

Erwartungswert

$$E[\bar{X}_n] = E[X_k] \rightarrow \text{S12A4}$$

Varianz

$$\text{var}(\bar{X}_n) = \frac{\text{var}(X_k)}{n} \neq \text{var}(X_k) \rightarrow \text{S12A4}$$



Gesetz d. grossen Zahlen

$$P(|\bar{X}_n - E[X_k]| > \epsilon) \leq \frac{\text{var}(X_k)}{n\epsilon^2}$$

starkes Gesetz d. grossen Zahlen

$$P(\lim_{n \rightarrow \infty} \bar{X}_n = E[X_k]) = 1$$

zentraler Grenzwertsatz

$$P\left(\frac{S_n - n \cdot E[X_k]}{\sqrt{n \cdot \text{var}(X_k)}} \leq x\right) \xrightarrow{n \rightarrow \infty} \Phi_{0,1}(x)$$

(normalisierte) Summe von i.i.d.  $X_k$  konvergiert gegen Standardnormalverteilung

Näherungsformeln allgemein:

$$P(S_n \leq x) \approx \Phi_{n\mu, \sqrt{n}\sigma}(x) \rightarrow \text{S11A10}$$

$$P(\bar{X}_n \leq x) \approx \Phi_{\mu, \frac{\sigma}{\sqrt{n}}}(x)$$

Näherung für binomialisch  $n, p$  verteilte Zufallsvariable  $X$  (mit Histogrammkorrektur):

$$P(X \leq m) \approx \Phi_{0,1}\left(\frac{(m+\frac{1}{2}) - np}{\sqrt{np(1-p)}}\right)$$

$$P(X \geq m) \approx 1 - \Phi_{0,1}\left(\frac{(m-\frac{1}{2}) - np}{\sqrt{np(1-p)}}\right) \rightarrow \text{S11A7/8}$$

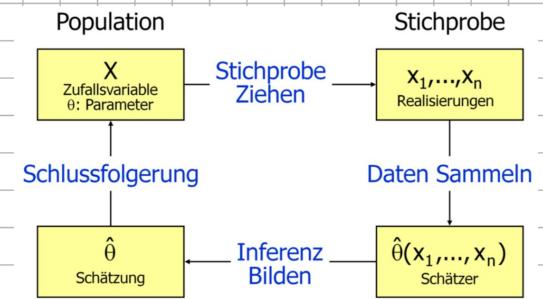
$$P(X = m) \approx 2\Phi_{0,1}\left(\frac{(m+\frac{1}{2}) - np}{\sqrt{np(1-p)}}\right) - 1 \rightarrow \text{S11A7/9}$$

# Schätzen von Parametern

## Stichprobe

Folge  $X_1, \dots, X_n$  von  $n$  i.i.d Zufallsvariablen

Wenn man eine Stichprobe zieht / realisiert, erhält man  $n$  unabhängige Realisierungen  $x_1, \dots, x_n$  der Zufallsvariable  $X$



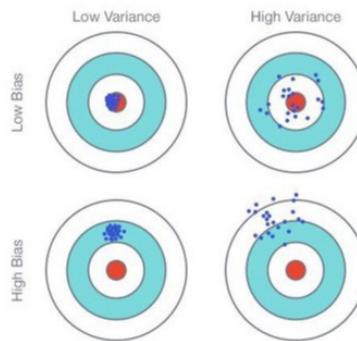
## Punktschätzer

Vorschrift  $T$ , mit welcher man aus einer Stichprobe  $X_1, \dots, X_n$  eine Schätzung für einen Parameter  $\theta$  berechnen kann

## bias

$$\text{bias}(T) = E[T] - \theta \rightarrow \text{S12A4}$$

- misst erwartete Verserrung des Schätzers  $T$
- falls  $\text{bias}(T) = 0$  nennt man  $T$  erwartungstreu



## mse (mean squared error)

$$\text{mse}(T) = E[(T - \theta)^2] = \text{var}(T) + (\text{bias}(T))^2$$

- misst erwartete quadratische Abweichung des Schätzers  $T$   
 $\rightarrow$  Mass für Güte eines Schätzers  $\rightarrow \text{S12A2}$
- entspricht bei erwartungstreuen Schätzern der Varianz des Schätzers  $\rightarrow \text{S12A1}$

## wichtige Formel Varianz (Repetition)

$$\text{var}(X) = E[X^2] - (E[X])^2 \rightarrow \text{S12A3}$$

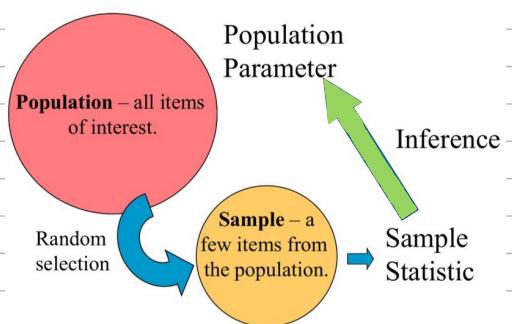
$$E[X^2] = \text{var}(X) + (E[X])^2 \rightarrow \text{S12A4}$$

## Schätzer für $\mu, \sigma^2, \sigma$

	Population	Sample
# of subjects	$N$	$n$
Mean	$\mu = \frac{\sum_{i=1}^N x_i}{N}$	$\bar{x} = \frac{\sum_{i=1}^n x_i}{n}$
Variance	$\sigma^2 = \frac{\sum_{i=1}^N (x_i - \mu)^2}{N}$	$S^2 = \frac{\sum_{i=1}^n (x_i - \bar{x})^2}{n-1}$
Standard deviation	$\sigma = \sqrt{\frac{\sum_{i=1}^N (x_i - \mu)^2}{N}}$	$S = \sqrt{\frac{\sum_{i=1}^n (x_i - \bar{x})^2}{n-1}}$

Note:  $S^2$  is the formula for unbiased sample variance, since we're dividing by  $n-1$ .  $\rightarrow \text{S12A3}$

Note: Finding  $S$  by taking  $\sqrt{S^2}$  reintroduces bias.  $\rightarrow \text{S12A3}$



## Schätzer bestimmen

gegeben:  $n$  Werte  $x_1, \dots, x_n$  (Stichprobe)

vorgegeben: Wahrscheinlichkeits(dichte)-Funktion  $f_X(x| \theta)$  mit unbekanntem Parameter  $\theta$

gesucht: Parameter  $\theta$ , damit vorgegebene Funktion  $f_X(x)$  bestmöglich zu Stichprobe passt

### Maximum-Likelihood-Methode

$$1. L(\theta) = f_X(x_1 | \theta) \cdots f_X(x_n | \theta) = \prod_{k=1}^n f_X(x_k | \theta)$$

$$2. \text{ ext: } \ln(L(\theta)) \quad \text{falls vereinfacht}$$

3. Kandidaten für  $\theta$

3.1 Nullstelle der Ableitung  $\rightarrow S1ZA5-7.1$

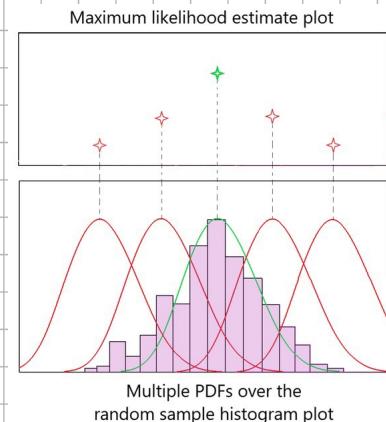
$$a. \frac{d}{d\theta} \text{ (ableiten nach } \theta)$$

$$b. \text{ Ableitung } \stackrel{!}{=} 0 \text{ setzen}$$

c. nach  $\theta$  auflösen

d. ext: falls mehrere Nullstellen:

$\rightarrow$  einsetzen und  $\theta$  so wählen, dass  $L(\theta)$  möglichst gross



3.2 kleinster und grösster Wert der Stichprobe  $\rightarrow S1ZA5, S1ZA1.2$

$$a. \theta = \max(x_1, \dots, x_n) \text{ und } \bar{\theta} = \min(x_1, \dots, x_n) \text{ setzen}$$

b. prüfen, ob dies  $L(\theta)$  maximiert

4.  $\theta$  so wählen, dass  $L(\theta)$  maximal wird

### Momenten-Methode $\rightarrow S1ZA7.2, S1ZA1.1$

1. Mittelwert der Zufallsvariable  $X$

$$M(\theta) = E[X] = \int_{-\infty}^{\infty} x \cdot f(x, \theta) dx$$

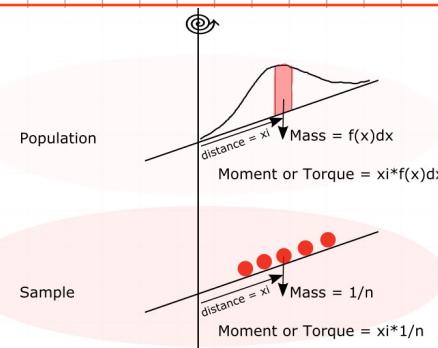
2. Stichprobenmittelwert

$$\bar{x} = \frac{1}{n} (x_1 + \dots + x_n) = \frac{1}{n} \sum_{j=1}^n x_j$$

3. Formeln aus Schritt 1. und 2. gleichsetzen

$$M(\theta) \stackrel{!}{=} \bar{x}$$

4. Gleichung nach  $\theta$  auflösen



# Konfidenzintervall für Mittelwert $\mu$

$$P(\mu \in KI) = 1-\alpha$$

## Konfidenzintervall bestimmen

gegeben:

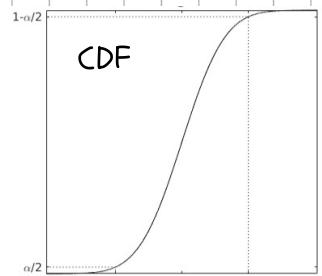
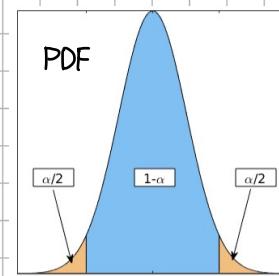
- $\bar{x}$  empirischer Mittelwert
- $\sigma$  Standard-Abweichung
- $n$  Umfang der Stichprobe
- $\alpha$  Fehlerwahrscheinlichkeit

gesucht:

KI Konfidenzintervall für  $\mu$  zu  $1-\alpha \rightarrow S13A2$

$$Z_{1-\frac{\alpha}{2}} = \Phi_{0,1}^{-1}(1-\frac{\alpha}{2}) \stackrel{TR}{=} \text{solve}(\text{normCdf}(-\infty, x, 0, 1) = 1-\alpha/2, x)$$

$$KI = \left[ \bar{x} - Z_{1-\frac{\alpha}{2}} \frac{\sigma}{\sqrt{n}}, \bar{x} + Z_{1-\frac{\alpha}{2}} \frac{\sigma}{\sqrt{n}} \right]$$



## Umfang n der Stichprobe bestimmen

gegeben:

- $\sigma$  Standard-Abweichung
- Länge des Konfidenzintervalls
- $\alpha$  Fehlerwahrscheinlichkeit

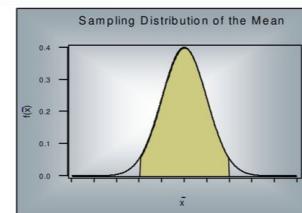
gesucht:

$n$  Umfang der Stichprobe  $\rightarrow S13A2.4$

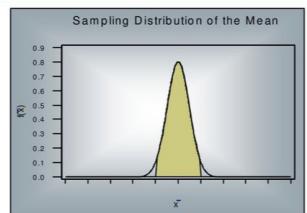
$$Z_{1-\frac{\alpha}{2}} = \Phi_{0,1}^{-1}(1-\frac{\alpha}{2}) \stackrel{TR}{=} \text{solve}(\text{normCdf}(-\infty, x, 0, 1) = 1-\alpha/2, x)$$

$$n = \frac{4}{L^2} Z_{1-\frac{\alpha}{2}}^2$$

When sampling from the same population, using a fixed confidence level, the **larger the sample size, n, the narrower the confidence interval.**



95% Confidence Interval:  $n = 20$



95% Confidence Interval:  $n = 40$